智能通信的人工智能基础 2：生成模型、协同学习与决策

廖振宇

电子信息与通信学院
华中科技大学
2026 年秋季学期

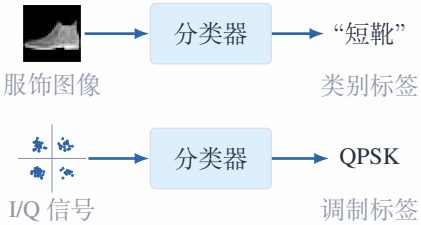
1
生成式模型

1 判别模型 VS 生成模型

判别/分类模型

Discriminative Model

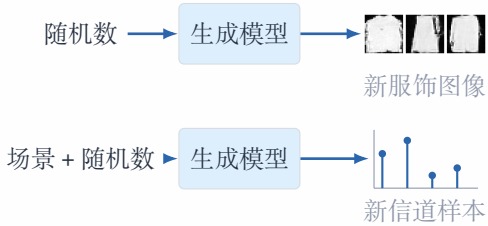
- 输入数据 $\mathbf{x}$，输出预测标签 y
- 学习 $p_\theta(y \mid \mathbf{x})$



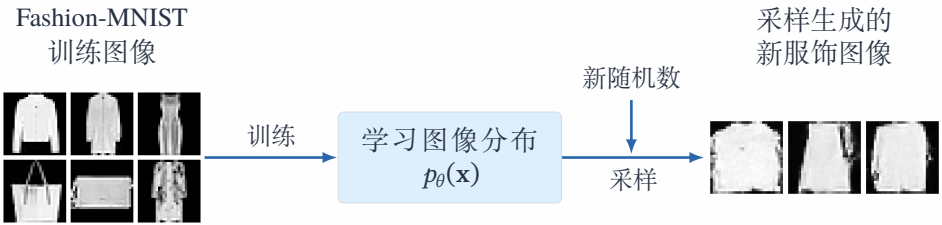
生成模型

Generative Model

- 无条件：学习 $p_\theta(\mathbf{x})$，采样产生**新样本**
- 条件生成：给定条件 c 时，学习 $p_\theta(\mathbf{x} \mid c)$

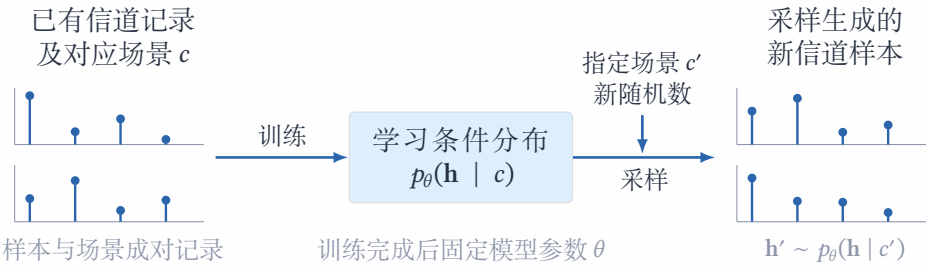


1 计算机视觉例子：生成 Fashion-MNIST 新图像



1. **训练**：使用 Fashion-MNIST 训练集图像，学习服饰数据“分布”
2. **生成**：固定模型，用新的随机采样得到**新的**服饰图像

1 智能通信例子：生成给定场景下的信道样本



1. **训练**：使用训练集的信道—场景对，学习各种场景内的信道（变化）分布
2. **生成**：固定模型与场景（**条件生成**），改变随机数，采样得到新信道

1 生成模型的比较与联系

方法	核心思路	训练目标
自编码器 AE	编码、解码，重建输入	重建误差
变分自编码器 VAE	对潜变量作概率建模/约束	重建项 + 先验约束（能采样）
生成对抗网络 GAN	生成器 + 判别器交替训练	真假判别与生成器对抗损失
扩散模型	针对加噪样本，学习去噪	针对已知噪声的预测误差

- **AE 与 VAE：**共享编码—解码思路，VAE 进一步引入概率建模与先验约束
- **GAN 与扩散模型：**GAN 依靠判别器提供监督反馈，扩散用已知噪声构造监督信号

1 自编码器：Autoencoder（AE）



$$\mathbf{z} = e_\phi(\mathbf{x}), \qquad \hat{\mathbf{x}} = g_\theta(\mathbf{z})$$

$$L_{\text{AE}}(\phi, \theta) = \frac{1}{N} \sum_{i=1}^{N} \left\| \mathbf{x}_i - g_\theta(e_\phi(\mathbf{x}_i)) \right\|_2^2$$

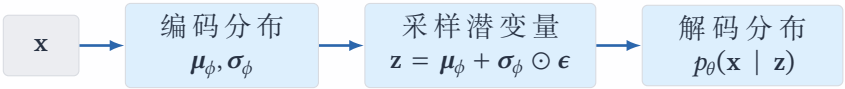
- **目标：**重建样本使其接近输入样本
- **训练：**最小化重建损失，共同更新编码器与解码器

思考

完成训练后，重建误差小，是否随便取，e.g. 高斯随机向量就能生成合理样本?

1 变分自编码器（VAE）

Variational Autoencoder (VAE)：编码器给出（近似）后验 $q_\phi(\mathbf{z} \mid \mathbf{x})$，解码器给出 $p_\theta(\mathbf{x} \mid \mathbf{z})$



$$q_\phi(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}\left(\boldsymbol{\mu}_\phi, \mathrm{diag}(\boldsymbol{\sigma}_\phi^2)\right), \qquad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, I)$$

- **近似后验与变分：**真实后验 $p_\theta(\mathbf{z} \mid \mathbf{x})$ 非线性解码器下**难算**。在选定的可计算分布族中优化参数 $q_\phi(\mathbf{z} \mid \mathbf{x})$ 来逼近，称为**变分法**
- **训练：**从 $q_\phi(\mathbf{z} \mid \mathbf{x})$ 采样，再用解码器重建输入
- **约束：**让编码分布靠近先验 $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$；距离加入损失函数
- **生成：**从预先设计的先验采样 $\mathbf{z}$，再经解码得到新样本

参考：Kingma 与 Welling，Auto-Encoding Variational Bayes

1 VAE 损失与 ELBO：重建项和先验约束

$$L_{\mathrm{VAE}}(\mathbf{x}) = \underbrace{-\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})} \log p_\theta(\mathbf{x} \mid \mathbf{z})}_{\text{重建项}} + \underbrace{D_{\mathrm{KL}}\big(q_\phi(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z})\big)}_{\text{先验约束}}$$

- **重建项：**要求解码分布给训练样本较高概率密度
- **KL 散度：**衡量（用来近似的）编码分布与先验的差异，非负
- **训练：**以 batch $\hat{\mathbb{E}}[L_{\mathrm{VAE}}(\mathbf{x})]$ 为损失函数，更新 ϕ, θ

ELBO：Evidence Lower Bound（证据下界）

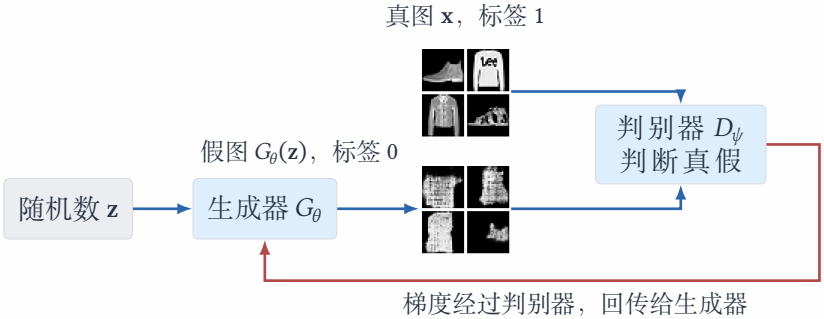
$$\mathrm{ELBO}(\mathbf{x}) = -L_{\mathrm{VAE}}(\mathbf{x}) \leq \log p_\theta(\mathbf{x})$$

最小化 VAE 损失，等价于最大化数据对数似然的可计算**下界**

KL：Kullback–Leibler 散度

1 生成对抗网络（GAN）

Generative Adversarial Network (GAN)



- **判别器：**学习区分**真实样本与生成样本**
- **生成器：**学习提高假图的判别得分（“混淆”判别器）；生成时**只用**生成器

1 GAN 损失：交替训练判别器与生成器

1. **固定生成器，最小化判别器 D_ψ 的二分类交叉熵**

   $$L_D(\psi) = -\hat{\mathbb{E}}_{\mathbf{x}\sim p_{\text{data}}} \log D_\psi(\mathbf{x}) - \hat{\mathbb{E}}_{\mathbf{z}\sim p(\mathbf{z})} \log\big(1 - D_\psi(G_\theta(\mathbf{z}))\big)$$

   - 真图得分趋向 1，假图得分趋向 0

2. **固定判别器，最小化生成器 G_θ 的损失**

   $$L_G^{\text{sat}}(\theta) = \hat{\mathbb{E}}_{\mathbf{z}\sim p(\mathbf{z})} \log\big(1 - D_\psi(G_\theta(\mathbf{z}))\big) \Rightarrow L_G(\theta) = -\hat{\mathbb{E}}_{\mathbf{z}\sim p(\mathbf{z})} \log D_\psi(G_\theta(\mathbf{z}))$$

   - 当 $D_\psi(G_\theta(\mathbf{z})) \approx 0$ 时，原始目标 $L_G^{\text{sat}}(\theta)$ 的梯度小；用**非饱和损失** $L_G(\theta)$

结论

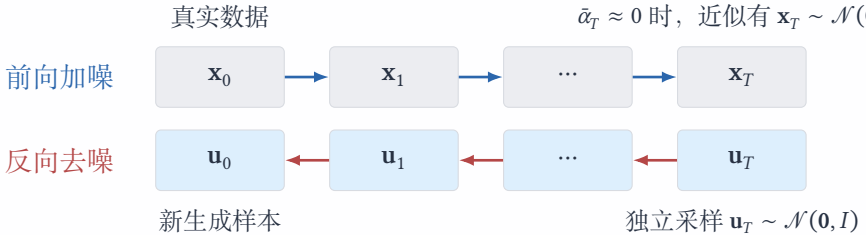
生成器和判别器交替更新，以判别器反馈指导生成器提升

$\hat{\mathbb{E}}_{s\in\mathcal{B}} f(s) = \frac{1}{B}\sum_{i=1}^{B} f(s_i)$；真实样本来自训练集，$\mathbf{z}$ 从先验采样

参考：Goodfellow 等，Generative Adversarial Nets，第 3 节

1 扩散模型：前向加噪与反向去噪

DDPM：Denoising Diffusion Probabilistic Models（去噪扩散概率模型）

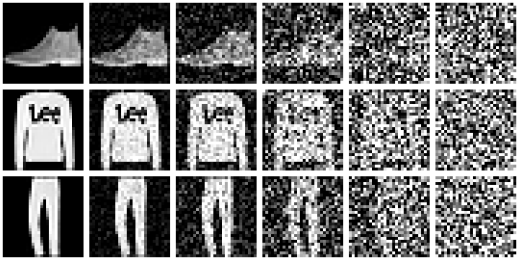


- **前向：** 采样噪声 $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, I)$，构造带噪样本 $\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$
- **反向：** 训练模型以预测噪声 $\hat{\boldsymbol{\epsilon}} = \epsilon_\theta(\mathbf{u}_t, t)$，进一步逐步采样 + 更新 $\mathbf{u}_t \to \mathbf{u}_{t-1}$

$\bar{\alpha}_t = \prod_{s=1}^{t}(1-\beta_s)$，$\beta_s$ 为第 s 步噪声方差，见下页

参考：Ho 等，DDPM

1 前向加噪：逐步加噪与直接采样



- 每行从同一张真实图像出发
- 从左到右噪声逐渐增强
- 加噪规则预先设定

1. **逐步加噪：** $\mathbf{x}_t = \sqrt{1-\beta_t}\,\mathbf{x}_{t-1} + \sqrt{\beta_t}\,\xi_t, \quad \xi_t \sim \mathcal{N}(\mathbf{0}, I)$
2. 由于各步 ξ_t 独立，定义 $\alpha_t = 1-\beta_t, \quad \bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s, \quad \bar{\alpha}_0 = 1$；可**直接采样：**

$$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}, \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, I)$$

- 实际训练：随机取 t 与 $\boldsymbol{\epsilon}$，**直接**构造 $\mathbf{x}_t$，以加噪过程中**已知**的 $\boldsymbol{\epsilon}$ 为监督目标

1 扩散的训练：预测噪声

1. **前向加噪：**取真实样本 $\mathbf{x}_0$，随机采样时间步 t 与噪声 $\boldsymbol{\epsilon}$，按前向公式构造 $\mathbf{x}_t$
2. **给定** $(\mathbf{x}_t, t)$，通过网络预测 $\hat{\boldsymbol{\epsilon}} = \epsilon_\theta(\mathbf{x}_t, t)$
3. 用已知噪声监督 $\boldsymbol{\epsilon}$，反向传播更新参数 θ

$$L_{\text{diff}}(\theta) = \hat{\mathbb{E}}_{\mathbf{x}_0,t,\boldsymbol{\epsilon}}\left[\frac{1}{d}\left\|\boldsymbol{\epsilon} - \epsilon_\theta(\mathbf{x}_t, t)\right\|_2^2\right]$$

- $\hat{\mathbb{E}}$ 对小批量中的 $\mathbf{x}_0, t, \boldsymbol{\epsilon}$ 样本取平均
- d 为样本维数，MSE（Mean Squared Error，均方误差）按维度平均
- 同一预测器接收不同的 t，学习处理不同噪声强度

参考：Ho 等，DDPM

1 噪声预测怎样用于去噪？

加噪过程：$\mathbf{x}_t = \sqrt{\bar{\alpha}_t}\,\mathbf{x}_0 + \sqrt{1-\bar{\alpha}_t}\,\boldsymbol{\epsilon}$

预测噪声 ⇒ 图像“去”噪

$$\hat{\mathbf{x}}_0 = \frac{\mathbf{x}_t - \sqrt{1-\bar{\alpha}_t}\,\epsilon_\theta(\mathbf{x}_t, t)}{\sqrt{\bar{\alpha}_t}}$$

- 减去估计噪声，再校正缩放

结论

训练学到噪声预测和“猜”图像能力，生成过程通过反复调用，逐步形成新样本

1 反向去噪：由噪声预测计算下一步

1. 输入 $\mathbf{u}_t$，预测噪声并计算**下一状态的条件均值**：

$$\mu_\theta(\mathbf{u}_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(\mathbf{u}_t - \frac{\beta_t}{\sqrt{1-\bar{\alpha}_t}}\epsilon_\theta(\mathbf{u}_t, t)\right)$$

2. 围绕均值采样，得到**下一步（随机！）状态**：$\boxed{\mathbf{u}_{t-1} = \mu_\theta(\mathbf{u}_t, t) + \sigma_t \boldsymbol{\eta}}, \boldsymbol{\eta} \sim \mathcal{N}(\mathbf{0}, I)$

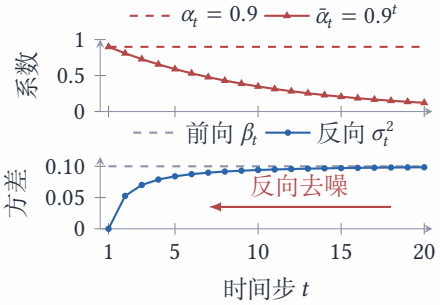
方差由加噪方案确定：

- 前向加噪：$\mathbf{x}_t = \sqrt{\alpha_t}\,\mathbf{x}_{t-1} + \sqrt{\beta_t}\,\boldsymbol{\xi}_t$
- 考虑后验 $q(\mathbf{x}_{t-1} \mid \mathbf{x}_t, \mathbf{x}_0)$ 的方差：

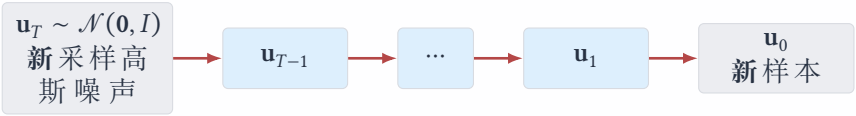
$$\sigma_t^2 = \tilde{\beta}_t = \beta_t \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}$$

- 最终 $\bar{\alpha}_0 = 1$，故 $\sigma_1 = 0$，最后一步只取均值
- $\boldsymbol{\eta}$ 是本步新采样的噪声，不是预测噪声

示意：考虑各步 $\beta_t = 0.1$



1 扩散生成：固定模型，逐步生成新样本



1. 初始化：独立采样 $\mathbf{u}_T \sim \mathcal{N}(\mathbf{0}, I)$
2. 对 $t = T, T-1, \ldots, 1$：利用当前状态预测噪声，计算均值，重新采样 $\mathbf{u}_{t-1}$
3. 迭代，最终输出 $\mathbf{u}_0$

结论

训练过程更新网络参数 θ；之后，生成过程中固定 θ，反复更新当前样本 $\mathbf{u}_t$

1 条件生成：CVAE 与 CGAN

共同任务：学习给定条件下的样本分布

$$p_\theta(\mathbf{x} \mid c) \approx p_{\text{data}}(\mathbf{x} \mid c), \qquad \mathbf{x}'_{c^*} \sim p_\theta(\cdot \mid c = c^*)$$

训练：成对数据 $\{(\mathbf{x}_i, c_i)\}_{i=1}^N$　　**生成：**固定 c^*，例如鞋类或城区场景

条件 VAE（CVAE）

Conditional Variational Autoencoder

- **模型：** $q_\phi(\mathbf{z} \mid \mathbf{x}, c)$，　$p_\theta(\mathbf{x} \mid \mathbf{z}, c)$
  $p_\theta(\mathbf{x} \mid c) = \int p_\theta(\mathbf{x} \mid \mathbf{z}, c) p(\mathbf{z})\, \mathrm{d}\mathbf{z}$
- **训练：**条件重建项与 KL 约束
- **生成：**取 $\mathbf{z} \sim p(\mathbf{z})$，再采样
  $\mathbf{x}'_{c^*} \sim p_\theta(\cdot \mid \mathbf{z}, c^*)$

参考：[5] Sohn 等，NIPS 2015

条件 GAN（CGAN）

Conditional Generative Adversarial Network

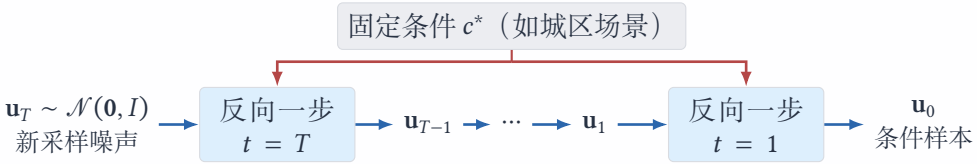
- **模型：** $\tilde{\mathbf{x}} = G_\theta(\mathbf{z}, c)$
  $D_\psi(\mathbf{x}, c)$，　$D_\psi(G_\theta(\mathbf{z}, c), c)$
- **训练：**在同一条件下对抗判别真假
- **生成：**取 $\mathbf{z} \sim p(\mathbf{z})$，直接输出
  $\mathbf{x}'_{c^*} = G_\theta(\mathbf{z}, c^*)$

参考：[6] Mirza 与 Osindero，2014

1 条件扩散：预测器与生成过程始终读取条件

$$\hat{\epsilon} = \epsilon_\theta(\mathbf{x}_t, t, c), \qquad L_{\text{cond}}(\theta) = \hat{\mathbb{E}}_{(\mathbf{x}_0,c),t,\boldsymbol{\epsilon}}\left[\frac{1}{d}\left\|\boldsymbol{\epsilon} - \epsilon_\theta(\mathbf{x}_t, t, c)\right\|_2^2\right]$$

$\hat{\mathbb{E}}$：对成对训练样本及本次抽取的 t, ϵ 取小批量平均



1. **训练：**对成对数据 $(\mathbf{x}_0, c)$ 加噪，以已知噪声监督预测器
2. **生成：**固定 c^* 与参数 θ，从新高斯噪声 $\mathbf{u}_T$ 开始
3. **每一步：**用 $\epsilon_\theta(\mathbf{u}_t, t, c^*)$ 计算反向均值，再采样

结论

条件控制目标场景，初始噪声与逐步采样保留该场景中的变化

1 课堂练习：训练目标与生成方法

1. 普通 AE 重建误差很小，是否能保证从标准高斯随机采样就生成合理样本？VAE 增加了什么约束？

2. 取 $\bar{\alpha}_t = 0.64$、$x_0 = 1$、$\epsilon = -0.5$
计算 x_t，并写出这次噪声预测的监督目标

3. 想生成“城区”场景的不同信道，条件和随机性分别是什么？
条件 GAN 中，只有生成器接收条件是否足够？

1 课堂练习：答案与解释

1. **AE 与 VAE**
   不保证，普通 AE 没有约束编码分布与指定先验一致
   VAE 在重建项之外加入 $D_{\mathrm{KL}}(q_\phi(\mathbf{z} \mid \mathbf{x}) \| p(\mathbf{z}))$

2. **带噪样本与监督目标**
   $x_t = \sqrt{0.64} \times 1 + \sqrt{0.36} \times (-0.5) = 0.5$
   目标是已知噪声 $\epsilon = -0.5$，不是带噪输入 $x_t = 0.5$

3. **条件与随机性**
   条件 c 指定城区，随机变量表达该场景下不同信道实现
   条件 GAN 的两方都应读取 c，使判别反馈针对给定场景

2
分布式机器学习

2 训练为什么需要多设备协作？

单机训练慢，或模型放不下 **计算与存储容量受限** → 把数据或模型分到多台设备 **分布式计算**

数据分散在不同基站或机构 **原始数据难以集中** → 在本地计算，交换模型更新 **联邦学习**

- 分布式机器学习：Distributed Machine Learning
- 联邦学习：Federated Learning（FL），**进一步**强调数据本地保留等约束

结论

两者都组织多方协作，**区别**在于计算条件与数据约束

参考：[12] Kairouz 等，Advances and Open Problems in Federated Learning，2021

2 分布式学习的范式与联邦学习

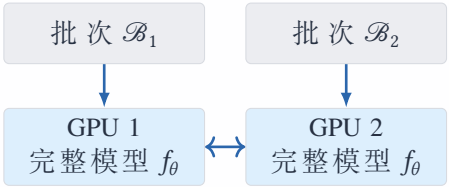


维度可组合：跨机构联邦学习 + 机构内部数据并行 + 中心聚合

参考：[10] Ben-Nun 与 Hoefler，2019，第 6–7 节 参考：[12] Kairouz 等，2021，第 1–2 节

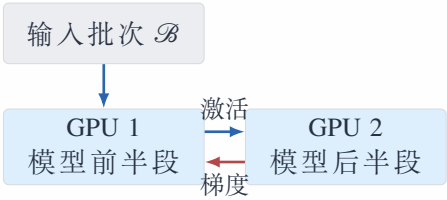
2 数据并行与模型并行

数据并行：完整模型，多份数据



- 每台设备保留完整模型
- 主要交换梯度或模型更新

模型并行：同一模型，分成多段

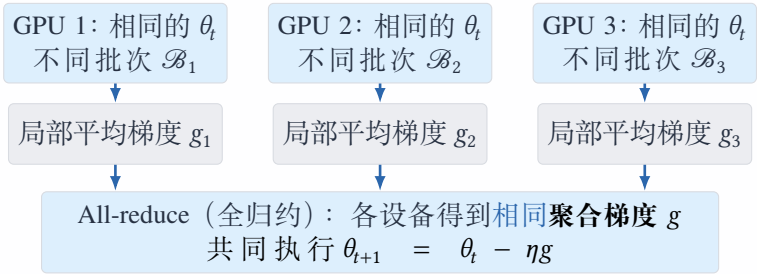


- 每台设备保留部分模型
- 前向传激活，反向传梯度

- 两类划分可以组合成混合并行，本节重点讨论**同步数据并行**

2 同步数据并行：本地求梯度，再共同更新

DDP：Distributed Data Parallel（分布式数据并行）



1. 从**相同参数**出发，各自在本地批次上前向计算并求梯度
2. **汇总**梯度，再使用相同优化器状态与更新规则

参考：PyTorch，Getting Started with Distributed Data Parallel

2 不同批量大小时的梯度聚合

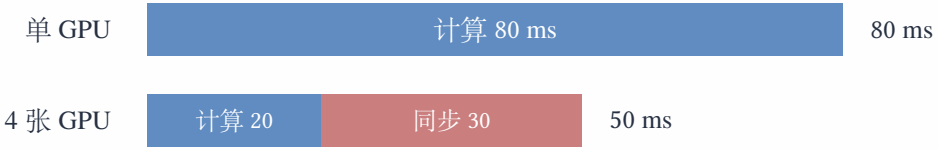
$$g_k = \frac{1}{B_k} \sum_{i \in \mathcal{B}_k} \nabla_\theta \ell_i(\theta_t), \qquad g = \sum_{k=1}^{K} \frac{B_k}{\sum_j B_j} g_k$$

设备	样本数	平均梯度
GPU 1	16	2
GPU 2	48	-2

$$g = \frac{16}{64} \times 2 + \frac{48}{64} \times (-2) = -1$$

- **原因**：以全体样本平均损失为目标时，每个样本应有相同权重

2 多设备加速为什么受通信限制？Com4AI



$$T_K \approx \underbrace{\max_k T_{\text{comp}}^{(k)}}_{\text{取最慢节点}} + T_{\text{sync}}, \qquad \text{加速比} = \frac{80}{20+30} = 1.6$$

- **慢节点（straggler）：**本轮计算或通信明显慢于其他节点的设备，常由算力、负载或链路差异造成
- **带来的问题：**同步训练需要等待慢节点，快节点空闲；每轮耗时增加，设备利用率与加速比下降
- **评估方案：**比较达到同一验证效果所需的总时间与累计通信量

参考：[10] Ben-Nun 与 Hoefler，2019，第 7 节

2 数据中心训练与联邦学习的侧重点

	典型数据中心数据并行	典型联邦学习
数据组织	可统一调度与重新分片	数据保留在不同客户端甚至不同机构
参与设备	连接稳定，管理统一	可用性、算力和链路存在差异
数据分布	常可随机打乱后划分	常有类别、设备和场景差异
同步方式	每步同步梯度	多步本地训练后聚合模型

结论

联邦学习属于分布式学习，但包含**数据归属与本地保留**约束

2 课堂练习：梯度聚合与训练速度

1. 两张 GPU 的本地批量分别为 8 和 24，平均梯度分别为 1 和 3
   以全体样本平均损失为目标，求聚合梯度
   若当前参数为 2、学习率为 0.1，更新后是多少？

2. 同一全局批量在单 GPU 上计算需 80 ms
   两张 GPU 各计算 40 ms，同步另需 10 ms，求加速比

3. 多座基站的原始数据需要保留在本地，可以采用哪种训练组织方式？交换什么信息？

2 课堂练习：答案与解释

1. **聚合梯度与参数更新**

   $g = \frac{8}{32} \times 1 + \frac{24}{32} \times 3 = 2.5$

   $\theta_{\text{new}} = 2 - 0.1 \times 2.5 = 1.75$

   按样本数加权，才能对应全体样本的平均损失

2. **加速比**

   每步时间 $T_2 = 40 + 10 = 50$ ms，加速比 $80/50 = 1.6$

   同步时间使结果低于理想的 2 倍

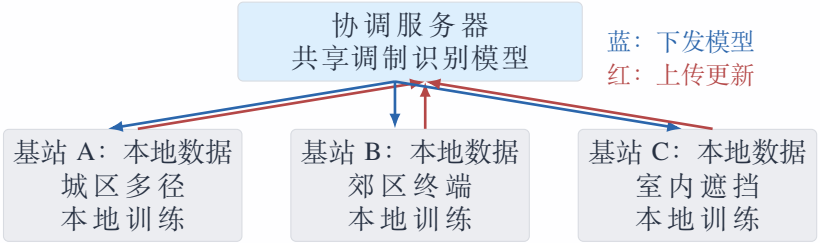
3. **数据本地保留**

   可采用联邦学习，在各站点训练并交换模型参数或更新

   原始样本保留本地，模型更新仍需考虑通信与信息保护

3
联邦学习

3 联邦学习：数据保留本地，共同训练模型

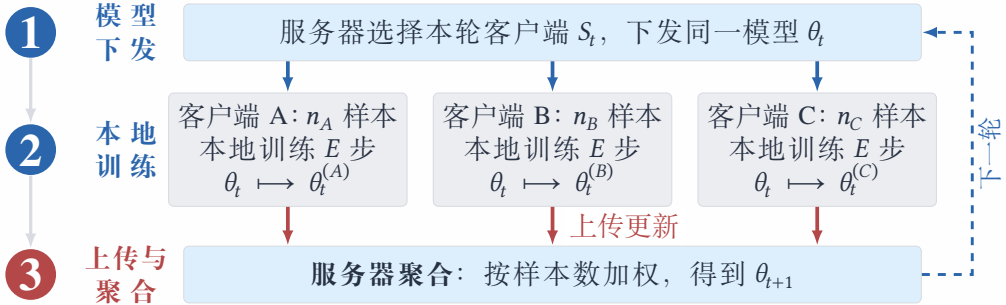


- **共享约束：**欧盟 GDPR 法规要求个人数据处理遵循用途限制与数据最小化
- 各站点的场景、样本不同，可以互补
- 希望多个站点共同改进模型，同时适应各自的数据特点
- **方案：**Federated Learning（联邦学习）

此处采用中心服务器协调场景，数据留在本地

参考：[17] 欧盟《通用数据保护条例》（GDPR），第 5–6 条

3 联邦平均方法：Federated Averaging（FedAvg）

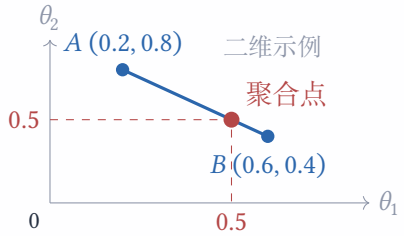


$$\theta_{t+1} = \sum_{k \in S_t} w_{k,t}\, \theta_t^{(k)}, \qquad w_{k,t} = \frac{n_k}{\sum_{j \in S_t} n_j}$$

- n_k 为本地样本数，只对**本轮参与客户端**归一化，权重和为 1

参考：[11] McMahan 等，Communication-Efficient Learning of Deep Networks from Decentralized Data，2017

3 FedAvg 的加权平均例子



- 仅考虑 A、B 参与，$n_A = 100,\ n_B = 300$

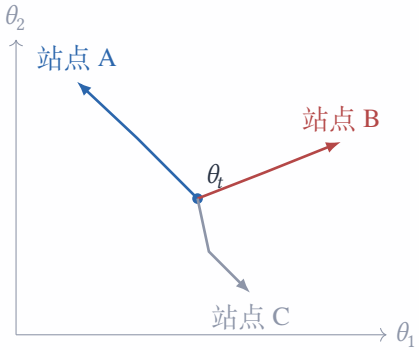
$$(\theta_{t+1})_1 = \frac{1}{4}(0.2) + \frac{3}{4}(0.6) = 0.5$$

$$(\theta_{t+1})_2 = \frac{1}{4}(0.8) + \frac{3}{4}(0.4) = 0.5$$

$$\Rightarrow \boxed{\theta_{t+1} = (0.5, 0.5)^\top}$$

	同步数据并行（DDP）	**FedAvg** [11]
聚合对象	同一点 θ_t 的梯度 g_k	本地训练 E 步后的参数 $\theta_t^{(k)}$
样本权重	$B_k / \sum_j B_j$（当前批量）	$n_k / \sum_j n_j$（本地数据量）

3 数据差异为什么会造成本地漂移？



参数空间中的本地更新方向示意

- 类别比例、信道与设备不同，各站点本地**损失不同**
- 如本地更新步数 E 较大，同步较少，可能导致更新方向彼此偏离

IID：Independent and Identically Distributed（独立同分布）；站点差异常表现为 non-IID

3 通信预算与模型更新的信息保护

通信预算例子

1. 10^7 个 FP32 参数，每个占 4 字节
2. 一次上传约 40 MB，即 320 Mbit
3. 20 Mbit/s 上行约需 16 s

模型更新仍包含信息

- **信息泄漏：**梯度依赖本地样本，可能暴露标签，某些特定条件下可重建输入
- **安全聚合：**成对随机掩码在求和时抵消，服务器只收到求和结果（依赖协议假设）
- **差分隐私：**裁剪 + 噪声，使有/无某客户端时的输出分布接近

FP32：32 位单精度浮点格式；每参数 32 bit = 4 字节（1 字节 = 8 bit）。

P 个参数占 $4P$ 字节，耗时 $32P/R$ 秒（速率 R bit/s）；本页 1 MB = 10^6 字节，1 Mbit = 10^6 bit。

参考：[12] Kairouz 等，Advances and Open Problems in Federated Learning，第 4 节

3 课堂练习：聚合权重与参与偏差

1. A 有 50 个样本，某参数本地训练后为 0.4
   B 有 150 个样本，该参数本地训练后为 0.8
   本轮只有 A、B 参与，求 FedAvg 结果与客户端等权结果
2. 本地步数从 $E = 1$ 增至 $E = 20$，通信频率和本地漂移可能怎样变化？
3. C 的链路较差，经常无法参与，增加哪些评价才能判断 C 是否被忽略？

3 课堂练习：答案与解释

1. **本轮聚合**

   $\theta_{t+1} = \frac{50}{200} \times 0.4 + \frac{150}{200} \times 0.8 = 0.7$

   客户端等权为 $(0.4 + 0.8)/2 = 0.6$，两种权重对应不同服务目标

2. **本地步数的取舍**

   每次通信之间完成更多本地更新，可减少单位本地更新对应的同步次数

   数据差异明显时，模型可能偏离共同起点更远，聚合效果需检验

3. **弱链路站点的评价**

   单独报告 C 的识别效果、参与频率与掉线情况

   同时查看最弱站点表现，避免只看总体平均

4
强化学习

4 强化学习：Reinforcement Learning（RL）

监督学习

- 数据给出输入与目标标签（**监督**）
- 模型学习预测标签
- 例：根据 I/Q 信号判断调制方式

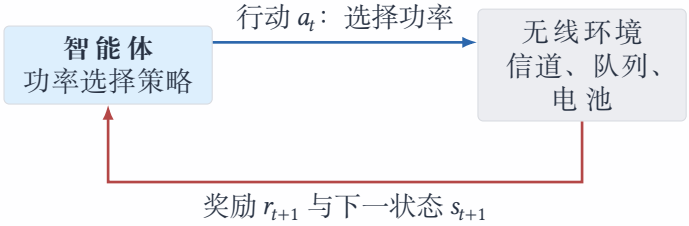
强化学习

- 智能体**采取**行动，与环境交互
- 根据**奖励**改进后续**决策**
- 例：根据信道情况选择发射功率

结论

“循环/交互”：行动会影响后续状态与收益，当前决策需要考虑/预测未来

4 例子：功率控制



- **状态** s_t：信道质量估计、当前队列、剩余电量
- **行动** a_t：在当前允许的低、中、高功率中选择
- **奖励** r_{t+1}：吞吐收益减去能耗与排队代价

4 马尔可夫决策过程：状态、转移与策略

定义 | MDP $(\mathcal{S}, \mathcal{A}, \mathcal{R}, p, \gamma)$：Markov Decision Process（马尔可夫决策过程）

- **状态空间 $\mathcal{S}$**：智能体所有可能状态，如信道、队列与电量的组合
- **行动空间 $\mathcal{A}$**：智能体所有可能行动；给定状态 s，所有可能行动 $\mathcal{A}(s) \subseteq \mathcal{A}$
- **奖励集合 $\mathcal{R} \subseteq \mathbb{R}$**：如本次行动的收益减去代价
- **联合转移概率 $p(s_{t+1}, r \mid s_t, a)$**：下一状态 s_{t+1} 与奖励 r 的联合分布，针对未来随机性的建模
- **折扣因子 $0 \le \gamma < 1$**：描述未来奖励相对于当前奖励的权重，考虑时间影响

- **策略**（给定状态，采取什么行动；要学习）：$\boxed{\pi(a \mid s) = \Pr(a_t = a \mid s_t = s)}$
- **马尔可夫性**：给定当前状态 s_t, a_t 后，过去历史不再提供额外信息

$$p(s_{t+1}, r_{t+1} \mid s_0, a_0, r_1, \ldots, s_t, a_t) = p(s_{t+1}, r_{t+1} \mid s_t, a_t)$$

参考：[13] Sutton 与 Barto，第 3 章

4 功率控制：发射功率怎样影响队列？

无线功率控制：行动 a_t 为发射功率；q_t 为本例中状态 s_t 中的待发送包数

- q_t、q_{t+1}：t 和 $t+1$ 时刻（开始时）的队列长度
- $d(s_t, a_t)$：本时隙最多可发送包数；A_t：时隙末新到达包数（确定性建模）

$$q_{t+1} = \underbrace{\max(q_t - d(s_t, a_t), 0)}_{\text{发送后剩余包数}} + \underbrace{A_t}_{\text{新到达包数}}$$

同一信道条件；先发送、后到达，$q_t = 5$、$A_t = 2$（单位：个包）

发射功率 a_t	当前队列 q_t	服务能力 $d(s_t, a_t)$	新到达 A_t	下一队列 q_{t+1}
较高功率	5	3	2	$5-3+2=4$
较低功率	5	1	2	$5-1+2=6$

本例：高功率减少队列积压，但通常更耗电；下一页考虑**长期收益**

4 累计回报与长期决策目标

- **即时奖励** r_{t+1}：时刻 t 采取行动后，对应的收益减去代价（**需设计！**）
- **累计回报** G_t：从时刻 t 开始，未来奖励（经折扣系数 γ 衰减后）的总和

$$G_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \cdots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

  - $0 \le \gamma < 1$：越远的奖励权重越小，γ 越大则越重视未来

两时隙例子：取 $\gamma = 0.9$，之后终止

方案/策略 $\pi(a \mid s)$	即时奖励 r_{t+1}	下一次奖励 r_{t+2}	累计回报 $G_t = r_{t+1} + \gamma r_{t+2}$
高功率，耗尽电量	5	0	$5 + 0.9 \times 0 = 5$
节约电量，继续发送	3	3	$3 + 0.9 \times 3 = 5.7$

- **策略目标：** $\max_\pi \mathbb{E}_\pi[G_0]$

4 行动价值：Q 函数怎样帮助采取行动？

定义 | 行动价值函数 $Q^\pi(s,a)$

从状态 s 先采取行动 a，再按策略 π 继续时的期望回报：

$$Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a]$$

- 条件与环境（随机性）共同决定的累计回报期望，可评估行动 a 的收益
- **最优行动价值/回报：** $Q^*(s,a) = \max_\pi Q^\pi(s,a)$

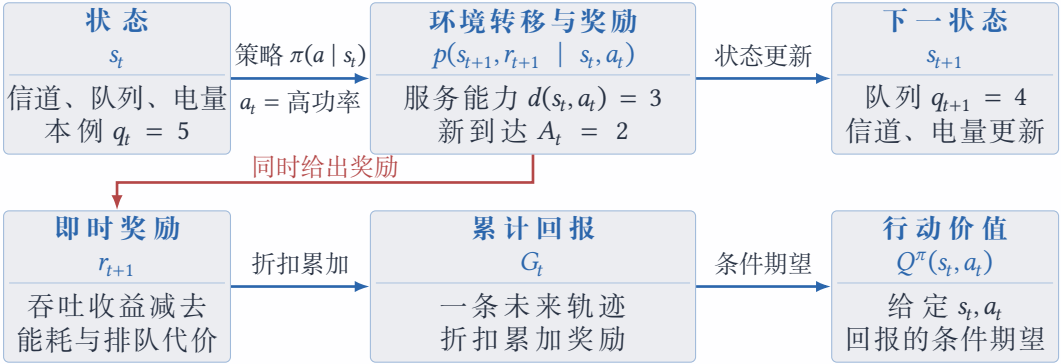
q_t 是队列长度；Q^π 是长期回报（的期望）

贪心策略：$a_{\text{greedy}} \in \arg\max_{a \in \mathcal{A}(s)} Q(s,a)$

- **思路：** 学习到 Q 若能近似 Q^*，可据此采取长期价值较高的行动

概念梳理

继续沿用功率控制例子：



$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} = r_{t+1} + \gamma r_{t+2} + \cdots,$$

$$Q^\pi(s, a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a].$$

4 Q 表：用价值估计支持行动选择

Q 表：按状态和行动存储当前的长期价值估计 $Q(s, a)$

状态 s	低功率 a_{L}	中功率 a_{M}	高功率 a_{H}
好信道、短队列	3.2	**4.6**	4.1
差信道、长队列	1.0	2.4	**3.6**

- **查表选行动：**按当前估计，贪心策略下第一行选择 a_{M}，第二行选择 a_{H}

怎样得到 Q 值表？

- 最优长期回报通常未知，需要通过交互逐步估计
- **怎样利用每次获得的奖励和下一状态，更新/修正 Q 表？**

4 Q-learning

定义 | Q-learning（无模型强化学习）

无需已知或估计环境模型 p，通过交互样本**估计最优行动价值** Q^*。

1. **回报分解：**本次奖励＋未来回报

$$Q^\pi(s,a) = \mathbb{E}_\pi[G_t \mid s_t = s, a_t = a] = \mathbb{E}_\pi\big[r_{t+1} + \gamma G_{t+1} \mid s_t = s, a_t = a\big]$$

2. **定义 | Bellman 最优方程：**最优价值函数 $Q^*(s,a)$ 应满足的一步递推关系

$$\boxed{Q^*(s,a) = \mathbb{E}_{(s',r)\sim p(\cdot,\cdot|s,a)}\big[r + \gamma \max_{a'} Q^*(s',a')\big]}$$

3. **构造目标 y：迭代计算求解最优** $Q^*(s,a)$

   3.1 **采样：**联合分布 p 未知，用实际反馈 (s_{t+1}, r_{t+1}) 估计期望

   3.2 **估计：**方程右侧 Q^* 未知，用更新前的当前估计替代

$$\boxed{y = r_{t+1} + \gamma \max_{a'} Q(s_{t+1}, a')}$$，终止时 $y = r_{t+1}$

[14] Watkins & Dayan (1992), § 2； [13] Sutton & Barto (2018), § 3.6、6.5

4 Q-learning：沿用 Q 表完成一次更新

$$\boxed{Q_{\text{new}}(s,a) = Q_{\text{old}}(s,a) + \alpha\big[y - Q_{\text{old}}(s,a)\big]}$$

考虑 $\gamma = 0.9, \alpha = 0.5$

- **一次交互采样：** s = 差信道、长队列，执行 $a = a_{\text{H}}$ = 高功率
- **环境反馈：** 实际奖励 $r = 1$，进入 s' = 好信道、短队列

Q 表更新例子

状态	低 a_{L}	中 a_{M}	高 a_{H}
s'：好、短	3.2	4.6	4.1
s：差、长	1.0	2.4	3.6

红：$Q(s, a_{\text{H}})$：3.6 ⟶ 4.37

蓝：下一状态的最大 Q 值估计

1. **构造目标：** 读取蓝框的最大值
   $y = 1 + 0.9 \times 4.6 = 5.14$
2. **计算误差：** 目标减去红框旧值
   $5.14 - 3.6 = 1.54$
3. **只更新红框内容**
   $3.6 + 0.5 \times 1.54 = \boxed{4.37}$

4 Q-learning 回顾：学习目标与经历来源

回顾：用交互经历改进行动价值估计

1. **评估行动：**用 Q 值估计长期价值，比较当前状态下的允许行动
2. **构造目标：**观察一次交互 (s, a, r, s')，结合实际奖励与未来价值估计
3. **修正估计：**用误差 $y - Q(s, a)$ 更新对应的 Q 表项

目标取决于任务是否结束

- **未终止：**保留未来价值估计，$y = r + \gamma \max_{a' \in \mathcal{A}(s')} Q(s', a')$
- **已终止：**没有后续奖励，$y = r$

问题：交互数据从何而来？

训练时应怎样选择行动、收集经历？e.g. 是否每次都选择**当前 Q 值最大的行动**？

4 探索与决策折中：ε-贪心策略

- 当前 Q 值表可能不准确：某个行动估计较低，可能只是**尝试不足**
- 若始终**选不到**，就难以获得纠正估计的反馈，更新对应 Q 值

利用已有估计

- 以概率 $1-\varepsilon$ 采取 Q 值最大的行动
- 使用目前认为较好的方案
- 未采取过的行动价值可能仍不准确

探索其他选择

- 以概率 ε 随机采取允许的行动
- 收集不同行动的反馈
- 短期收益可能降低

注意区别：学习目标与实际行动

构造目标时取 $\max Q$，实际收集经历时仍可探索其他允许行动。

4 深度 Q 网络：Deep Q-Network（DQN）

Q 表的局限

- 每个状态–行动对都要存储一个数值
- 信道、队列、电量的组合可能很**多**
- 状态连续变化时，无法为每个状态建表

输入：当前状态 $s = (h, q, b)$
信道质量、队列长度、剩余电量

↓

神经网络，共享参数 θ

↓

输出： $Q_\theta(s, a_{\mathrm{L}})$ 低功率　$Q_\theta(s, a_{\mathrm{M}})$ 中功率　$Q_\theta(s, a_{\mathrm{H}})$ 高功率

- 仍以估计 Q^* 为目标，用共享网络参数 θ 表示当前价值估计
- 输出仍是长期价值估计，不是行动概率；通过反向传播学习 θ

训练效率问题

- 若每次只用最新经历，连续时隙的信道、队列往往相近，旧经历也只用一次
- **怎样减弱样本的时间相关性，并复用已经收集的数据？**

4 经验回放（Experience Replay）：保存 + 抽样

解决方法：把经历存入回放缓冲区 $\mathcal{D}$，每次随机抽取 B 条用于训练

$$e_t = (s_t, a_t, r_{t+1}, s_{t+1}, d_t), \qquad s_t = (h_t, q_t, b_t)$$

h_t, q_t, b_t：信道、队列、电量；$d_t = 1$ 表示终止，$d_t = 0$ 表示未终止

功率控制的回放缓冲区例子：

经历	当前状态 s_t	行动 a_t	奖励 r_{t+1}	下一状态 s_{t+1}	d_t
e_{10}	(差, 5, 8)	高功率	1.8	(差, 4, 6)	0
e_{11}	(差, 4, 6)	低功率	−0.1	(差, 5, 5.5)	0
e_{30}	(好, 2, 7)	中功率	1.8	(好, 0, 6)	0
		… 后续交互经历继续存入 …			

- **抽样实例（$B = 2$）：**本次取 $\{e_{10}, e_{30}\}$；下次仍可能抽到 e_{10}
- **作用：**打散时间顺序，减弱样本相关性；重复抽样，复用已有反馈

4 DQN 损失与训练循环

- **抽取 B 条经历：**第 i 条记作 $(s_i, a_i, r_i, s_i', d_i)$
- **构造损失函数：**

$$y_i = r_i + \gamma(1 - d_i)\max_{a'} Q_{\theta^-}(s_i', a'), \qquad L(\theta) = \frac{1}{B}\sum_{i=1}^{B}\big(Q_\theta(s_i, a_i) - y_i\big)^2.$$

- **当前网络 θ 接受梯度更新；目标网络 θ^- 暂时固定**
  1. **交互并存储：**观察 s_t，按 ε-贪心采取允许行动，把完整经历存入缓冲区 $\mathcal{D}$
  2. **抽样并训练：**随机抽取 B 条，用固定的 θ^- 计算 y_i，最小化 $L(\theta)$ 更新 θ；将 y_i 视为常数，不沿目标分支反向传播
  3. **定期同步并继续：**每 C 次参数更新令 $\theta^- \leftarrow \theta$，继续交互与抽样

为什么保留目标网络 θ^-？

暂时固定下一状态的**价值估计**，缓和当前网络不断追逐变化目标的收敛问题

4 奖励设计：吞吐、能耗与排队代价

无线功率控制例子：根据信道、待发送队列和剩余电量，选择本时隙发射功率

- **状态** $s_t = (h_t, q_t, b_t)$：信道、队列、电量；**行动** a_t 决定功率 P_t
- λ, μ 分别为**能耗**与**排队代价**权重；固定时隙长度，能耗正比于功率

$$r_{t+1} = \underbrace{R_t}_{\text{本时隙吞吐收益}} - \lambda \underbrace{P_t}_{\text{发射功率}} - \mu \underbrace{q_{t+1}}_{\text{下一时隙队列}}$$

同一信道，$q_t = 3$、$A_t = 0$；取 $\mu = 0.2$

假设行动	吞吐 R_t	功率 P_t	队列 q_{t+1}	$\lambda = 0.2$	$\lambda = 1$
高功率	3	2	0	2.6	1.0
低功率	2	0.5	1	1.7	1.3

- 提高能耗权重后，即时奖励的偏好从高功率转为低功率

4 课堂练习：价值更新与功率选择

1. $Q(s,a)=1$，$r=0.5$，$\max_{a'} Q(s',a')=3$
   取 $\gamma=0.9$、$\alpha=0.2$，求非终止转移的一步目标与更新结果
2. 若下一状态改为真正终止，目标与更新结果分别是多少？
3. 奖励只含吞吐收益时，功率选择可能出现什么倾向？
   加入能耗惩罚后，应同时观察哪些指标？硬约束怎样处理？

4 课堂练习：答案与解释

1. **非终止转移**

   $y = 0.5 + 0.9 \times 3 = 3.2$

   $Q_{\text{new}} = 1 + 0.2(3.2 - 1) = 1.44$，目标包含后续价值估计

2. **真正终止**

   $y = 0.5$，$Q_{\text{new}} = 1 + 0.2(0.5 - 1) = 0.9$

   任务已结束，未来回报项归零

3. **奖励与约束**

   只奖励吞吐可能偏向高功率，加入能耗项后应同时检查吞吐、能耗与时延

   通过允许行动集合等机制满足功率、电量与干扰硬限制

4 第二讲总结

问题或约束	对应方法
描述同一场景中的样本变化	学习 $p_\theta(\mathbf{x} \mid c)$ 的条件生成模型
单设备计算或容量受限	分布式数据并行、模型并行
原始数据需保留在不同站点	联邦学习，本地训练与模型聚合
行动影响后续状态与收益	强化学习，优化期望累计回报

4 进一步学习：强化学习

1. **理解状态、策略与回报**

   Sutton 与 Barto，Reinforcement Learning: An Introduction，第 2 版
   第 3 章理解 MDP，第 6 章理解时序差分与 Q-learning

2. **复算价值更新**

   Dive into Deep Learning：Q-Learning
   对照本讲算例，分别计算普通转移与终止转移

3. **理解 DQN 的稳定训练机制**

   Mnih 等，Human-level control through deep reinforcement learning，2015
   重点解释经验回放、目标网络与训练损失的关系

4 强化学习应用视频：行走与上下楼梯

课后选看：点击视频标题，在具体任务中理解强化学习

1. **【补档】看深度强化如何逐步迭代学会行走**

   Bilibili：BV1tm4y1h79M

   观看提示：留意训练过程中运动表现的变化，联系反复交互与策略改进。

2. **AI 学习如何上下楼梯（深度强化学习）**

   Bilibili：BV1Cy421e71b

   观看提示：思考上下楼梯需要哪些状态信息，以及智能体能够控制哪些行动。

带着问题看

- 如果由你设计任务，**状态**、**行动**、**奖励**分别是什么？
- 奖励怎样兼顾前进、稳定与能耗？

5 参考文献（1/4）：数据与生成模型基础

[1] H. Xiao, K. Rasul, R. Vollgraf.
Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms.
arXiv:1708.07747, 2017. 数据与代码

[2] G. E. Hinton, R. R. Salakhutdinov.
Reducing the Dimensionality of Data with Neural Networks.
Science, 313(5786): 504–507, 2006.

[3] D. P. Kingma, M. Welling.
Auto-Encoding Variational Bayes.
International Conference on Learning Representations (ICLR), 2014. arXiv:1312.6114.

[4] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, Y. Bengio.
Generative Adversarial Nets.
Advances in Neural Information Processing Systems 27 (NIPS), 2014. arXiv:1406.2661.

5 参考文献（2/4）：条件生成与扩散

[5] K. Sohn, X. Yan, H. Lee.
Learning Structured Output Representation using Deep Conditional Generative Models.
Advances in Neural Information Processing Systems 28 (NIPS), 2015.

[6] M. Mirza, S. Osindero.
Conditional Generative Adversarial Nets.
arXiv:1411.1784, 2014.

[7] J. Ho, A. Jain, P. Abbeel.
Denoising Diffusion Probabilistic Models.
Advances in Neural Information Processing Systems 33 (NeurIPS), 2020. arXiv:2006.11239.

[8] S. J. D. Prince.
Understanding Deep Learning.
MIT Press, 2023. 生成模型、GAN、VAE 与扩散模型的教材阅读

5 参考文献（3/4）：分布式与联邦学习

[9] S. Li.
Getting Started with Distributed Data Parallel.
PyTorch Tutorials，官方在线教程，更新于 2025-09-23，访问于 2026-10-26.

[10] T. Ben-Nun, T. Hoefler.
Demystifying Parallel and Distributed Deep Learning: An In-Depth Concurrency Analysis.
ACM Computing Surveys, 52(4), Article 65: 1–43, 2019. arXiv:1802.09941.

[11] H. B. McMahan, E. Moore, D. Ramage, S. Hampson, B. Agüera y Arcas.
Communication-Efficient Learning of Deep Networks from Decentralized Data.
International Conference on Artificial Intelligence and Statistics (AISTATS),
Proceedings of Machine Learning Research 54: 1273–1282, 2017.

[12] P. Kairouz, H. B. McMahan et al.
Advances and Open Problems in Federated Learning.
Foundations and Trends in Machine Learning, 14(1–2): 1–210, 2021.
doi:10.1561/2200000083.

5 参考文献（4/4）：强化学习与数据保护

[13] R. S. Sutton, A. G. Barto.
Reinforcement Learning: An Introduction.
2nd edition, MIT Press, 2018. 第 3、6 章：MDP 与时序差分学习

[14] C. J. C. H. Watkins, P. Dayan.
Q-learning.
Machine Learning, 8: 279–292, 1992. doi:10.1007/BF00992698.

[15] V. Mnih, K. Kavukcuoglu, D. Silver et al.
Human-level control through deep reinforcement learning.
Nature, 518: 529–533, 2015. doi:10.1038/nature14236.

[16] A. Zhang, Z. C. Lipton, M. Li, A. J. Smola.
Dive into Deep Learning.
Cambridge University Press, 2023. 在线版第 17 章：强化学习，访问于 2026-10-27.

[17] European Parliament and Council. *Regulation (EU) 2016/679 (GDPR).*
Official Journal L 119, 4 May 2016, pp. 1–88. Articles 5–6.